

Execution-Aligned Progressive Noise for Consistent Asynchronous Replanning in Generative Robot Policies

Anonymous Authors

Abstract—Continuous asynchronous replanning is essential for real-time generative robot policies, but independent stochastic initialization can cause mode switching and inconsistent continuation across action chunks. We propose Execution-Aligned Progressive Noise (EAPN), which introduces structured stochasticity at both inter-chunk and intra-chunk levels. Across replanning steps, EAPN propagates a shared noise trajectory and aligns it with the actual execution displacement, establishing execution-aligned inter-chunk correlation. Within each action chunk, it models temporal correlation along action time. The aligned stochastic history is further combined with committed action context to condition subsequent generation, allowing new chunks to continue from execution-consistent generative states rather than restart from independent noise. We evaluate EAPN on D3IL, Kinetix, LIBERO, and real-world manipulation tasks. EAPN improves multimodal behavior consistency on D3IL and achieves an average success rate of 88.59% on Kinetix. On LIBERO, it remains robust and maintains strong task performance even under long inference delays. Real-robot experiments further achieve 90.0% success on Object Storage and 96.7% on bimanual Cloth Folding, demonstrating reliable continuous execution under asynchronous replanning.

I. 引言

Flow Matching 等生成式模型近年来逐渐成为机器人决策与控制中的重要建模范式，并被广泛用于动作序列生成 [1]–[4]。相比确定性回归策略，生成式策略能够刻画复杂且具有多模态性的条件行为分布，从而覆盖同一任务条件下多种合理的未来运动方式。然而，这类模型依赖多步迭代生成，而机器人闭环控制需要以更高频率持续输出动作，由此形成低频生成与高频控制之间的时间尺度失配。为缓解这一矛盾，现有 flow-based policies、Vision–Language–Action (VLA) models 以及 World–Action Models 普遍采用 Action Chunking 与异步执行：策略一次预测一段未来动作，并在当前 chunk 持续执行的同时生成下一 chunk [5], [8], [24]。但由于推理期间机器人仍在持续运动，新预测返回时对应的真实执行状态已经向前推进，从而带来 prediction–execution misalignment、动作陈旧以及相邻 Action Chunks 切换不连续等问题。

围绕异步执行所引起的时间错位问题，现有研究主要从动作约束、执行时刻校正以及生成过程引导等角度，提高连续 Action Chunks 之间的时序一致性与轨迹连续性。RTC 与 Training-Time RTC 利用已确定的 action prefix 对新 chunk 的生成过程施加约束 [8], [9]；VLASH 与 FutureRTC 进一步估计新预测实际生效时对应的 execution-time context，以减轻观测、推理与执行之间的时间错位 [11], [13]；Legato、SEAM 和 Soft RTC 则分别通过 continuation dynamics、velocity guidance 以及 soft action prior，引导新生成轨迹与已有执行历史保持更平滑的衔接 [10], [18], [19]。

尽管上述方法能够从不同层面对实时执行中的时间不

一致进行有效补偿，其核心约束通常集中于已执行或即将执行的轨迹前缀，而对脱离前缀引导后的自由生成部分缺乏显式的跨推理一致性约束。因此，现有方法主要关注动作空间中的连续性与执行对齐，而连续生成过程中的随机状态依赖尚未被充分建模。与此同时，大多数方法仍沿用彼此独立的随机初始化范式，即每一轮生成过程均从与上一轮推理无关的 Gaussian noise 出发。对于具有多峰条件分布的 Flow-based 生成式策略，不同的随机初始化可能将时间上高度重叠的连续推理过程引向不同但均具有较高概率的局部生成模式。因此，即使受约束的动作前缀能够保持连续，一旦生成过程逐渐进入缺乏显式前缀引导的后续动作区间，新生成轨迹仍可能偏离上一轮推理所对应的行为模态，并转向另一条同样合理但具有不同运动意图或操作策略的轨迹。

这种跨推理的模态切换并不一定表现为明显的单步动作错误，因此难以仅通过局部轨迹连续性加以识别。然而，在需要持续保持运动意图、接触关系或操作策略的长时序机器人任务中，不同模态之间的切换可能引起运动方向、末端执行器状态或后续操作语义的不一致。随着多个 Action Chunks 连续执行，这类不一致会进一步累积为明显的执行偏差，降低任务成功率，甚至导致任务失败。因此，除了校正异步执行带来的时间错位之外，如何在连续推理过程中维持生成轨迹的行为模态一致性，并减少由独立随机初始化引起的不必要模态切换，仍是现有 Action Chunk 连续执行方法尚未充分解决的问题。

如图 1 所示，Flow inversion 得到的初始噪声在同一 episode 内呈现显著且随观测间隔增大而衰减的时间相关性，而在不同 episodes 之间近似不相关，为 EAPN 的跨推理结构化噪声建模提供了经验依据。

基于上述分析与观察，本文提出 Execution-Aligned Progressive Noise (EAPN)，一种面向连续生成重规划的随机状态依赖建模方法。不同于仅在动作空间约束连续生成结果，EAPN 从生成过程本身出发，对连续 Action Chunk 之间以及 Chunk 内部的随机状态依赖进行显式建模。本文从两个互补层面构造结构化随机性：一方面，在连续策略调用之间建立 execution-aligned inter-chunk stochastic dependency，使相邻 Action Chunks 中具有真实执行对应关系的随机状态能够持续传播；另一方面，在单个 Action Chunk 内引入 intra-chunk temporal correlation，使不同时间步对应的随机变量具有与动作序列时间结构相一致的相关性。二者共同构成完整的 EAPN 随机源建模机制，从而在不直接约束确定性动作输出的情况下，为连续生成过程提供具有时间结构的随机先验。本文的主要贡献概括如下：

- **揭示连续 Action Chunk 间初始噪声的显著相关性。** 本文通过对采用独立高斯噪声训练的标准 Flow Matching 策略进行潜变量反演，发现相邻 Action Chunk 对应的反演初始噪声具有显著相关性：相关




Fig. 1. 标准 $\pi_{0.5}$ 动作策略的帧间隔反演揭示了初始噪声的时间局部依赖。模型使用逐 token 独立 Gaussian noise 训练，反演过程不包含 EAPN 结构。(a) 16 个保留验证回合的执行对齐反演初始噪声及独立 Gaussian 参考；原始空间中的 5-NN 同回合命中率为 100%。(b) 同回合平均余弦相似度为 0.774，不同回合为 0.043，独立 Gaussian 参考为 0.000。(c) 当观测间隔从 5 帧增至 45 帧时，同回合相似度由 0.855 连续下降至 0.378。粗线表示 16 个回合的均值，阴影表示 95% bootstrap 置信区间。(d) 回合 B 第 20–65 帧的十个真实观测与反演点逐一对应。

峰值随实际执行位移同步偏移，执行对齐位置的相关性随窗口位移增大而逐渐衰减。

- **跨 Chunk 与 Chunk 内联合的相关噪声建模。** 本文提出 EAPN，从 inter-chunk 与 intra-chunk 两个层面构建结构化随机相关性：前者在连续推理之间递推噪声状态，后者在单个 Action Chunk 内引入时间相关噪声。两者共同形成跨推理、跨时间步的连续随机先验，以降低独立噪声初始化引起的随机漂移与模态切换。
- **通过多基准与真机实验验证方法有效性。** 在 D3IL、Kinetix 和 LIBERO 上评估任务性能、跨 chunk 一致性与延迟鲁棒性，并通过组件消融分析跨 chunk 与 chunk 内噪声相关性的作用。真机物品收纳与双臂叠衣任务分别取得 90.0% 和 96.7% 的成功率，进一步验证方法在真实异步重规划中的有效性。

II. 相关工作

A. 异步 Action Chunk 执行与时间对齐

Action Chunking 通过一次预测多步未来动作降低生成式策略的调用频率，但推理与持续执行之间的时间差会进一步引入 prediction–execution misalignment [4], [5]. RTC 将异步执行表述为带 committed action prefix 的条件生成

问题，在采样期间固定即将执行的历史动作并生成剩余后缀 [8]; Training-Time RTC 将该约束前移至训练阶段，使策略直接学习给定历史前缀后的 continuation [9]. REMAC 进一步利用 masked action chunking 处理计划动作与真实执行之间的偏差 [12], VLASH 与 FutureRTC 则分别通过未来状态滚动和 execution-time observation/state prediction 改善新 chunk 的条件对齐 [11], [13]. DiscreteRTC 从离散扩散的 native inpainting 出发实现异步后缀生成 [25], Action ControlNet 则利用轻量 delay-aware residual adapter 在冻结大部分策略参数的情况下补偿执行期间的状态变化 [26]. 类似的 inference delay、chunk overlap 与 temporal alignment 问题也已出现在 World–Action Models 的异步部署中 [24]. 这些工作主要解决连续执行中历史状态、动作与新预测之间的时间对齐问题。

B. 跨 Chunk Continuation 与多模态一致性

除执行时刻对齐外，另一类研究直接优化连续 action chunks 的 continuation quality. BID 通过多候选采样并结合 backward coherence 与 forward contrast 选择兼顾历史一致性和未来合理性的轨迹 [17], Self-Guided Action Diffusion 则利用上一决策对当前 diffusion proposal 进行自引导，以降低多候选搜索的计算开销 [27]. Legato 将

连续 Flow Matching generation 中的 spurious multimodal switching 作为关键问题, 并通过 training-time continuation 与 schedule-shaped guidance 学习更自然的跨 chunk 延续 [10]; SEAM 从独立 Gaussian latents 可能引起的 multimodal bifurcation 出发, 通过上一 chunk 的未执行尾部构造 velocity guidance [19]; Soft RTC 则将 hard prefix 扩展为可编辑的 soft action prior [18]。进一步地, ChunkFlow 通过 seam-aware learning、overlap blending 及一阶/二阶连续性约束显式优化 chunk boundary [28], FocalPolicy 从多 chunk 的时间域与频率域结构建模长期 coherence [29], POTR 则通过 prior-corrected guidance 与 orthogonal trust region 约束采样期修正的幅度和方向 [30]。上述方法主要通过 candidate selection、action/velocity guidance、overlap constraint 或 learned continuation dynamics 使当前预测向历史轨迹保持一致, 而本文进一步关注连续 inference 的 stochastic initialization 本身是否具有时间依赖。

C. Source Prior 与相关随机初始化

近期研究开始重新审视生成式机器人策略的 source distribution。Streaming Flow Policy 从上一动作附近的窄 Gaussian 出发, 将生成轨迹与真实动作轨迹联系起来 [31]; Action-to-Action Flow Matching、WarmPrior 和 Temporal Policy 分别利用历史 proprioception 或近期动作构造 history-informed source, 以缩短 transport path 并增强时间一致性 [21]–[23]; LeaP 进一步根据当前 proprioceptive state 学习 Gaussian source 的均值和自适应方差 [32]。PAINT 则从 initial-noise selection 的角度, 通过 flow inversion 寻找能够自然满足历史 prefix 的随机初始化 [20]。这些工作共同表明, 生成起点本身是 flow-based policy 的重要设计维度。

III. 方法

A. 问题定义与方法概览

在第 k 次 inference 时, flow-based policy 根据当前观测 o_k 生成长度为 H 的未来动作序列

$$A_k = [a_{k,1}, \dots, a_{k,H}] \in \mathbb{R}^{H \times D_a}. \quad (1)$$

标准 Flow Matching 从 source noise $Z_k \in \mathbb{R}^{H \times D_a}$ 出发, 并沿线性概率路径

$$X_{k,t} = (1-t)A_k + tZ_k, \quad U_k = Z_k - A_k \quad (2)$$

B. Execution-Aligned Structured Noise

连续异步重规划中, 不同 Action Chunk 之间的随机状态并不存在固定索引对应关系, 而应根据机器人实际执行进度建立动态对应。因此, EAPN 从两个时间尺度显式建模生成过程中的随机状态依赖: 跨 Chunk 的 execution-aligned dependency 和 Chunk 内的 temporal dependency。

EAPN 首先建立连续生成过程中的 stochastic dependency structure。考虑到异步 Action Chunking 导致连续预测窗口在物理时间上发生偏移, EAPN 从 inter-chunk 和 intra-chunk 两个时间尺度建模随机状态之间的依赖关系。EAPN 首先构造同时具有 intra-chunk 与 inter-chunk 相关性的 structured source。为描述实现中的共享噪声轨迹, 可将其等价写成一个跨 inference 持续的 shared AR(1) process G_t 与一个窗口内 private AR(1) process $U_{k,h}$:

$$G_t = \rho G_{t-1} + \sqrt{1-\rho^2} \epsilon_t^G, \quad \epsilon_t^G \sim \mathcal{N}(0, I), \quad (3)$$

$$U_{k,h} = \rho U_{k,h-1} + \sqrt{1-\rho^2} \epsilon_{k,h}^U, \quad \epsilon_{k,h}^U \sim \mathcal{N}(0, I), \quad (4)$$

并以

$$z_{k,h} = \sqrt{\gamma} G_{T_k+h} + \sqrt{1-\gamma} U_{k,h} \quad (5)$$

构造第 k 个 chunk 的 source token。 $\rho \in [0, 1]$ 控制 action-time correlation 的衰减速度, $\gamma \in [0, 1]$ 控制共享噪声历史与当前窗口随机创新之间的比例。

由于两个 AR(1) 过程均以标准 Gaussian 为平稳边缘分布, 式 (5) 对任意单个 token 满足

$$z_{k,h} \sim \mathcal{N}(0, I). \quad (6)$$

同一 chunk 内的相关性随位置距离衰减; 跨 chunk 时, 共享轨迹按照真实窗口位移 Δ_k 重新索引, 因此有

$$\text{Cov}(z_{k+1,h}, z_{k,j}) = \gamma \rho^{|\Delta_k+h-j|} I. \quad (7)$$

这意味着最大的 stochastic dependence 自动落在执行对齐位置 $j \approx h + \Delta_k$, 而不是固定在相同 token index。需要强调的是, 式 (6) 仅说明单 token Gaussian marginal 保持不变; 完整 $H \times D_a$ source 的 joint covariance 已由 structured noise 改变。因此本文并不将完整 EAPN 表述为 training-free distribution-preserving sampler, 而是让模型在训练阶段显式适应该 joint source structure。

C. History-Conditioned Noise Representation

仅建立相关噪声仍不足以使策略理解“当前随机状态来自哪一段历史”, EAPN 因此将上一 chunk 的随机历史显式编码为策略条件。

给定上一轮 source Z_{k-1} , 根据实际执行位移 Δ_{k-1} 将其移动到当前 action-time window:

$$\bar{Z}_{k-1} = \mathcal{A}(Z_{k-1}, \Delta_{k-1}), \quad (8)$$

其中 $\mathcal{A}(\cdot)$ 对仍具有时间对应关系的 noise tokens 做 shift/alignment, 并对不存在历史对应的位置使用有效性掩码 m_k 标记。随后 conditioner 计算

$$c_k^{\text{hist}} = \mathcal{C}_\phi(\bar{Z}_{k-1}, \Delta_{k-1}, d_k, m_k), \quad (9)$$

并将 c_k^{hist} 注入 Flow Matching policy。这里, Δ_{k-1} 告诉模型上一随机轨迹已经被消费了多少步, d_k 描述当前 inference delay, 而 m_k 用于区分有效历史与 episode 首次推理/历史失效状态。

因此, EAPN 实际学习的并非普通 $v_\theta(o_k, X_{k,t}, t)$, 而是

$$v_\theta(o_k, X_{k,t}, t, c_k^{\text{hist}}, A_k^{\text{pre}}), \quad (10)$$

其中 A_k^{pre} 表示已确定的 committed prefix。该设计使 correlated source 不再只是隐藏在 sampler 中的统计变化, 而成为网络能够显式利用的历史条件。

IV. 实验与结果

本节在统一设置下依次报告标准策略反演、D3IL、Kinetix、LIBERO 与真实机器实验, 证明本文所提出方法的有效性。




Fig. 2. EAPN 方法示意图

A. 标准策略反演：执行对齐潜变量结构

为检验连续 Action Chunk 对应的初始噪声是否存在跨重规划相关性，我们对 $\pi_{0.5}$ 进行潜变量反演分析。该策略在训练过程中对 Action Chunk 各时间位置独立采样 Gaussian source，且连续推理之间不存在显式的噪声关联。因此，其反演潜变量可以用于分析连续动作生成过程中是否自然形成跨 Chunk 的随机依赖结构。我们从保留验证集中选取 16 个 episodes，实际执行位移 $D = 1, \dots, 9$ 的成对重叠 Action Chunks。随后利用训练后的条件向量场将对应动作序列反演至 noise space，并分析不同执行位移下相邻 Action Chunk 的潜变量相关结构。

如图 3 所示，在三个代表性执行位移 $D = 1, 5, 9$ 下，潜变量相关性的峰值均出现在 $j - h = D$ 的执行对齐位置，而非固定的相同位置对应关系。这表明，即使标准策略采用独立 Gaussian source 进行训练，物理时间上重叠的连续 Action Chunks 在反演噪声空间中仍呈现稳定的执行对齐相关结构。该观察说明连续动作生成过程中存在与实际执行进度一致的跨 Chunk 随机依赖，并为式 (7) 中随执行位移动态变化的相关结构提供了经验依据。

B. D3IL：多模态保持与跨推理模式一致性

D3IL 专门用于评估 imitation policy 对多模态行为分布的建模能力，并提供具有可解释性的离散 behavior descriptors [33]。本文将 D3IL 作为机制诊断基准，而非主要的实时性 benchmark，用于检验 EAPN 是否能够在连续推理过程中保持原策略的多模态行为结构。

采用 Avoiding 任务进行评估，该任务中，不同的绕障路径对应清晰且可判定的行为模式，因此能够直接刻画策略在多次 rollout 间的模式保持能力。实验固定相同的 initial-state distribution，并对每个初始状态执行配对 rollouts，从

TABLE I

D3IL Avoiding 上的任务成功率与连续重规划行为一致性

Method	Success $\uparrow$	MSR $\downarrow$	Switch Gap $\downarrow$
DDPM-ACT	73.13% (351/480)	3.969%	0.001913
EAPN	78.96% (379/480)	3.167%	0.001672

而比较 IID noise 与 EAPN 两种采样机制下的任务成功率及跨重规划行为一致性。本文采用 DDPM-ACT 作为基础策略。该模型结合扩散式动作生成与 Action Chunking，通过条件去噪一次预测多步未来动作。选择该模型的原因在于，其同时具备随机生成与分块预测机制，与 EAPN 所研究的跨重规划随机初始化问题直接对应。

Mode Switch Rate (MSR) 定义为所有 episodes 中，同一障碍层内行为模式发生变化的相邻可判定重规划对数量与全部此类有效对数量之比；正常的障碍层推进不计为切换。

实验结果表明，EAPN 相较于 DDPM-ACT 将任务成功率从 73.13% 提升至 78.96%，提高了 5.83 个百分点。同时，MSR 从 3.969% 降低至 3.167%，Switch Gap 从 0.001913 降低至 0.001672。这表明 EAPN 能够在连续重规划过程中降低相邻执行动作之间的不连续性，使策略在多次推理与执行过程中呈现出更稳定的行为模式。

结合 Avoiding 任务中不同行为模式具有明确几何含义这一特点，上述结果进一步表明，EAPN 有助于减少独立噪声重采样引起的跨推理模式跳变，在保持原始 diffusion policy 多模态行为能力的同时，提高 rollout-level 的行为一致性与任务执行成功率。



Fig. 3. 标准 $\pi_{0.5}$ 策略中的执行对齐潜变量结构。实际执行位移 $D = 1, 5, 9$ 时，相邻 Action Chunks 的潜变量相关矩阵。黑色虚线表示由实际执行位移确定的对齐位置 $j = h + D$ 。

TABLE II
EAPN 在 Kinetix mjc_swimmer 上的组件消融。

Variant	Success $\uparrow$	Switch Gap $\downarrow$	Tail Gap $\downarrow$
T-RTC	46.60	1.58	1.58
+ Inter-Chunk Noise	76.89	1.55	1.51
+ Intra-Chunk Noise	78.85	1.54	1.50
EAPN	79.26	1.55	1.50

C. Kinetix: 高动态延迟鲁棒性

Kinetix 是基于 Jax2D 的开放式 2D 物理控制环境 [14]。为保证横向可比性，本文遵循其异步执行协议：预测 horizon 设为 $H = 8$ ，并将 Kinetix 协议中的 committed/inference prefix length 记为 D ，取

$$D \in \{0, 1, 2, 3, 4\}. \quad (11)$$

在每个 delay 设置下，对允许连续供给动作的 execution horizon 范围进行评测，并同时报告 12 个任务的平均结果与逐任务结果。如图 4 所示，随着 execution horizon K 或 inference delay D 增大，各方法的成功率整体下降，而 EAPN 的性能退化更为平缓，并在多数任务上保持更高的成功率。这表明 EAPN 能够有效缓解异步推理中由延迟引起的动作失配，在高动态控制任务中提升策略对推理延迟的鲁棒性。

D. EAPN 组件消融

为量化 EAPN 中不同噪声相关性设计的独立贡献，我们在 Kinetix 的持续控制任务 mjc_swimmer 上进行组件消融。该任务要求策略在较长时间范围内维持连续运动，对连续重规划过程中由 chunk 切换引入的扰动较为敏感，因此适合同时考察任务性能与跨 chunk 轨迹一致性。具体而言，我们以 T-RTC 为基线，依次引入 Inter-Chunk Noise 和 Intra-Chunk Noise，并与完整 EAPN 进行比较。

实验采用 Success Rate、Switch Gap 和 Tail Gap 作为评价指标。Success Rate 衡量整体任务完成能力；Switch Gap 定义为相邻 action chunks 在实际切换位置处动作之间的 ℓ_2 距离，用于衡量重规划边界处的局部动作不连续性；Tail Gap 则计算 committed prefix 之后新生成后缀与上一轮时间对齐计划之间的平均 ℓ_2 偏差，用于刻画连续推理过程中自由生成部分的轨迹一致性。

表 II 给出了各组件的逐步贡献。在 T-RTC 基础上加入 Inter-Chunk Noise 后，Success Rate 由 46.60 提升至 76.89，

提高 30.29 个百分点，同时 Switch Gap 和 Tail Gap 均有所降低。进一步引入 Intra-Chunk Noise 后，Success Rate 提升至 78.85，并取得最低的 Switch Gap 和 Tail Gap。完整 EAPN 进一步达到最高的 79.26 Success Rate，而两项连续性指标与前一配置保持相近水平。从数值上看，主要性能增益来自跨 chunk 噪声关联，而 chunk 内噪声相关性在此基础上提供进一步改善。这一结果表明，对连续推理过程中噪声相关结构进行显式建模，有助于提高长时程控制中的任务性能，并维持较稳定的跨 chunk 轨迹连续性。

E. LIBERO: 带推理延迟的通用操作基准

LIBERO 包含 Spatial、Object、Goal 和 Long 四个操作 suites [15]。本文以 $\pi_{0.5}$ 为主要 backbone，低延迟与高延迟实验采用独立的训练配置及 checkpoint。

两组实验的评测延迟集合为

$$\mathcal{D}_{\text{low}} = \{1, 2, 3, 4\}, \quad \mathcal{D}_{\text{high}} = \{5, 10, 15\}. \quad (12)$$

低延迟实验采用 $K = 5$ ，并匹配小延迟范围训练或微调；高延迟实验采用 $K = 25$ ，并在 $D \in \{0, 5, 10, 15, 20\}$ 的长延迟采样配置下重新训练或微调。两组结果仅在各自协议内比较，不构成同一模型上的连续延迟扫描。前者考察小窗口位移下的性能保持，后者考察连续执行旧 chunk 时的任务鲁棒性，均报告四个 suites 的成功率及其平均值。对于每个任务，异步 runtime 在 policy inference 期间继续执行旧 chunk，并根据实际 action buffer consumption 得到窗口位移 Δ_k 。若系统首先执行 E_k 步后才启动下一次推理，则可写为 $\Delta_k = E_k + d_k$ ；EAPN 使用该真实位移对齐 previous noise。

表 III 显示，T-RTC 的平均成功率整体与 VLASH 相近，而 EAPN 在 $D = 1-4$ 上保持了 96.4%–97.0% 的平均成功率。在 $D = 4$ 时，EAPN 相比 VLASH 提高 4.9 个百分点，表明该组合在低延迟区间能够更好地抑制性能随延迟增加而下降。表 IV 中，T-RTC 将三个高延迟设置下的平均成功率由 VLASH 的 71.5%、70.3% 和 68.3% 提升至 89.8%、80.3% 和 73.0%。在此基础上，EAPN 在 $D = 10$ 和 $D = 15$ 时进一步提高 2.7 和 2.0 个百分点，

F. Real-World Experiments

为验证 EAPN 在真实机器人系统中的执行可靠性，我们设计了两个具有不同操作特性的真机任务：物品收纳




Fig. 4. Kinetix 异步推理结果对比。左侧分别给出固定 $D = 1$ 时不同 execution horizon K 下，以及不同 inference delay D 下的 12 个任务平均成功率；右侧给出各任务的逐任务结果。

TABLE III
LIBERO 在低推理延迟设置下的成功率 (%), $D \in \{1, 2, 3, 4\}$ 。

Method	D	Spatial	Object	Goal	Long	Avg. SR
VLASH	1	94.2	98.6	96.4	94.8	96.0
	2	93.0	99.2	94.6	94.0	95.2
	3	92.2	99.4	94.8	92.6	94.8
	4	86.0	97.4	92.6	90.8	91.7
T-RTC	1	94.6	99.0	94.8	95.4	96.0
	2	92.4	98.4	95.0	93.2	94.8
	3	92.2	98.0	96.0	95.0	95.3
	4	88.8	95.6	94.2	90.2	92.2
EAPN	1	97.6	99.0	96.4	92.6	96.4
	2	97.8	99.4	98.0	92.8	97.0
	3	95.6	99.2	96.4	94.4	96.4
	4	96.4	99.0	96.6	94.2	96.6

TABLE IV
LIBERO 在高推理延迟设置下的成功率 (%), $D \in \{5, 10, 15\}$ 。
VLASH 为公开权重 warm-start 后的 $K = 25$ 本地复测结果。

Method	D	Spatial	Object	Goal	Long	Avg. SR
VLASH	5	69.0	71.0	79.0	67.0	71.5
	10	68.0	69.0	80.0	64.0	70.3
	15	70.0	72.0	78.0	53.0	68.3
T-RTC	5	87.0	96.0	90.0	86.0	89.8
	10	76.0	84.0	91.0	70.0	80.3
	15	70.0	80.0	86.0	56.0	73.0
EAPN	5	87.0	92.0	89.0	85.0	88.3
	10	80.0	88.0	91.0	73.0	83.0
	15	72.0	82.0	88.0	58.0	75.0

(Object Storage) 和双臂叠衣 (Cloth Folding)。前者主要涉及刚性物体的连续抓取与放置，用于评估异步连续重规划下的任务完成能力；后者进一步引入柔性物体形变、长时程操作和双臂协同，对跨 chunk 一致性和执行稳定性提出更高要求。两个任务的代表性执行过程如图 5 所示。

为保证公平比较，所有方法均采用相同的 $\pi_{0.5}$ 作为基础策略，并在每个任务上使用相同的训练数据与实验设置。其中，Object Storage 使用 216 个训练 episodes，Cloth Folding 使用 3,056 个训练 episodes。

1) *Object Storage*: 该任务要求机器人连续抓取桌面上的多个厨房日常物体，包括蔬菜、调料瓶等。该任务要求机器人将其全部放入指定篮筐，测试物体在外观、尺寸

和几何形状上存在差异，每次 rollout 前随机改变物体的初始位置，以降低固定布局对实验结果的影响。

该任务使用 216 个 episodes 训练 $\pi_{0.5}$ 基础策略。对于每种方法，我们执行 20 次独立 rollout，单次最大执行时间设为 60s。仅当机器人在规定时间内完成全部物体的收纳时记为成功，否则记为失败。评价指标为任务成功率。

2) *Cloth Folding*: 该任务用于进一步评估长时程柔性物体操作中的执行稳定性。衣物在操作过程中持续发生非刚性形变，且双臂需要保持长期协调，因此该任务具有更强的历史依赖，对连续重规划过程中的跨 chunk 一致性提出了更高要求。

该任务使用 3,056 个 episodes 训练 $\pi_{0.5}$ 基础策略。实验选取 3 件颜色和尺寸不同的衣物，每种方法在每件衣




Fig. 5. 真机实验任务及代表性执行过程。(a) Object Storage: 机器人连续抓取桌面上的多个物体并放置到指定篮筐中。(b) Cloth Folding: 双臂机器人从不同衣物初始构型出发, 通过连续重规划完成衣物折叠。

TABLE V

两个真机任务上的成功率。所有方法均采用相同的 $\pi_{0.5}$ 基础策略。

Method	Success Rate $\uparrow$	
	Object Storage	Cloth Folding
Naive Async	65.0% (13/20)	63.3% (19/30)
RTC	80.0% (16/20)	60.0% (18/30)
T-RTC	80.0% (16/20)	63.3% (19/30)
VLASH	85.0% (17/20)	93.3% (28/30)
EAPN	90.0% (18/20)	96.7% (29/30)

物上执行 10 次独立 rollout, 共计 30 次测试。每次 rollout 前重新设置衣物的初始构型, 最大执行时间设为 3 min。仅当机器人在规定时间内完成目标折叠时记为成功。

如表 V 所示, EAPN 在两个真机任务上均取得最高成功率。在 Object Storage 上, EAPN 达到 90.0%, 较 Naive Async 和 VLASH 分别提升 25.0 和 5.0 个百分点, 表明其能够提升异步连续重规划下的任务执行可靠性。

在更具挑战性的 Cloth Folding 上, EAPN 达到 96.7% 的成功率, 相较 Naive Async 提升 33.4 个百分点, 并略高于 VLASH 的 93.3%。该结果进一步表明, EAPN 在具有较强历史依赖、柔性物体形变和双臂协同的长时程操作中, 能够保持稳定的连续执行。

总体而言, 两个真机任务从刚性物体连续操作和长时程柔性操作两个方面验证了 EAPN 在真实机器人异步连续重规划中的有效性。

V. 结论

本文针对生成式机器人策略在连续异步重规划中的行为模式不一致问题, 提出 Execution-Aligned Progressive Noise (EAPN)。基于相邻动作窗口反演初始噪声的相关性观察, EAPN 联合构建 inter-chunk 与 intra-chunk 噪声相关结构: 前者依据实际执行位移, 关联连续预测窗口中具有物理时间对应关系的噪声位置; 后者在单个动作窗口内引入随时间间隔衰减的噪声相关性。通过进一步将对齐后的随机历史作为生成条件, EAPN 旨在减少独立随机初始化引起的不必要模式切换, 促进连续重规划中行为模式的稳定延续。在 D3IL、Kinetix、LIBERO 及真实机器人任务上的实验表明, EAPN 能够改善任务成功率与跨 Chunk 动作衔接, 并在长推理延迟下保持较好的执行表现。物品收纳与双臂叠衣实验进一步验证了其在真实操作中的有效性。上述结果支持了通过执行对齐的结构化噪声建模, 改善生成式机器人策略连续重规划一致性与执行鲁棒性的设计思路。

REFERENCES

- [1] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, “Flow Matching for Generative Modeling,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2023.
- [2] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al., “ π_0 : A Vision-Language-Action Flow Model for General Robot Control,” *arXiv preprint arXiv:2410.24164*, 2024.
- [3] Physical Intelligence, K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, et al., “ $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization,” *arXiv preprint arXiv:2504.16054*, 2025.
- [4] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song, “Diffusion Policy: Visuomotor Policy Learning via Action Diffusion,” *Int. J. Robot. Res.*, 2024, arXiv:2303.04137.
- [5] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,” in *Proc. Robot. Sci. Syst. (RSS)*, 2023.
- [6] S. Ge, S. Nah, G. Liu, T. Poon, A. Tao, B. Catanzaro, D. Jacobs, J.-B. Huang, M.-Y. Liu, and Y. Balaji, “Preserve Your Own Correlation: A Noise Prior for Video Diffusion Models,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023.
- [7] I. Larchenko, G. Zarin, and A. Karnatak, “Task Adaptation of Vision-Language-Action Model: 1st Place Solution for the 2025 BEHAVIOR Challenge,” *arXiv preprint arXiv:2512.06951*, 2025.
- [8] K. Black, M. Y. Galliker, and S. Levine, “Real-Time Execution of Action Chunking Flow Policies,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2025, arXiv:2506.07339.
- [9] K. Black, A. Z. Ren, M. Equi, and S. Levine, “Training-Time Action Conditioning for Efficient Real-Time Chunking,” *arXiv preprint arXiv:2512.05964*, 2025.
- [10] Y. Liu, H. Yu, J. Zhao, B. Li, D. Zhang, M. Li, W. Wu, Y. Hu, J. Xie, J. Guo, D. Wang, and Y. Gao, “Learning Native Continuation for Action Chunking Flow Policies,” *arXiv preprint arXiv:2602.12978*, 2026.
- [11] J. Tang, Y. Sun, Y. Zhao, S. Yang, Y. Lin, Z. Zhang, J. Hou, Y. Lu, Z. Liu, and S. Han, “VLASH: Real-Time VLAs via Future-State-Aware Asynchronous Inference,” *arXiv preprint arXiv:2512.01031*, 2025.
- [12] H. Wang, G. Zhang, Y. Yan, Y. Shang, R. R. Kompella, and G. Liu, “Real-Time Robot Execution with Masked Action Chunking,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2026, arXiv:2601.20130.
- [13] H. Jiang, Y. Zou, B. Liang, B. Liu, F. Meng, and S. Liu, “FutureRTC: Real-Time Robot Execution with Anticipatory-Conditioned Action Chunking,” *arXiv preprint arXiv:2607.24008*, 2026.
- [14] M. Matthews, M. Beukman, C. Lu, and J. N. Foerster, “Kinetix: Investigating the Training of General Agents through Open-Ended Physics-Based Control Tasks,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2025.
- [15] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone, “LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning,” *arXiv preprint arXiv:2306.03310*, 2023.
- [16] M. Shukor, D. Aubakirova, F. Capuano, P. Kooijmans, S. Palma, A. Zouitine, M. Aractingi, C. Pascal, M. Russi, A. Marafioti, et al., “SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics,” *arXiv preprint arXiv:2506.01844*, 2025.
- [17] Y. Liu, J. I. Hamid, A. Xie, Y. Lee, M. Du, and C. Finn, “Bidirectional Decoding: Improving Action Chunking via Guided Test-Time Sampling,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2025.
- [18] D. Liu, Z. Zheng, Y. Sun, L. Zhang, Y. Liu, and H. Wan, “Action-Prior Denoising for Smooth Real-Time Chunking,” *arXiv preprint arXiv:2605.25537*, 2026.
- [19] D. Zhan, X. Xu, J. Li, and J. Tang, “SEAM: Smooth Execution of Action-Chunked Motion for Vision-Language-Action Policies,” *arXiv preprint arXiv:2607.04609*, 2026.
- [20] T.-B. Ho, Q.-T. Nguyen, T.-L. Ha, G.-B. Nguyen, V.-T. Nguyen, L. Dinh, M. N. Vu, D. M. H. Nguyen, A. T. Le, and N. A. Vien, “Start Right, Arrive Right: Asynchronous Execution via Initial Noise Selection,” *arXiv preprint arXiv:2606.19774*, 2026.
- [21] S. Kang, C. Kim, K. Wang, L. Zhao, and K. Lee, “WarmPrior: Straightening Flow-Matching Policies with Temporal Priors,” *arXiv preprint arXiv:2605.13959*, 2026.
- [22] J. Jia, G. Li, X. Chen, T. An, Y. Hu, J. Li, X. Guo, and J. Yang, “Action-to-Action Flow Matching,” in *Proc. Robot. Sci. Syst. (RSS)*, 2026, arXiv:2602.07322.

- [23] D. Miller and M. Jagersand, “Temporal Policy: History-Initialized Action Generation for Robotic Learning from Demonstration,” *arXiv preprint arXiv:2607.29482*, 2026.
- [24] Motubrain Team, “World Action Models in Real Time: An Empirical Study of Smooth Execution via Asynchronous Deployment,” *arXiv preprint arXiv:2608.01880*, 2026.
- [25] P. Wang, K. Hong, C. Peng, K. Driggs-Campbell, M. Tomizuka, C. Xu, and C. Tang, “DiscreteRTC: Discrete Diffusion Policies are Natural Asynchronous Executors,” *arXiv preprint arXiv:2604.25050*, 2026.
- [26] T. Guo and M. Guo, “Action ControlNet: A Lightweight Delay-Aware Adapter for Smooth Asynchronous Control in Vision-Language-Action Models,” *arXiv preprint arXiv:2606.25985*, 2026.
- [27] R. Malhotra, Y. Liu, and C. Finn, “Self-Guided Action Diffusion,” *arXiv preprint arXiv:2508.12189*, 2025.
- [28] Z. Yang, Y. Shi, M. Yao, W. Xue, Y. Jueluo, and L. Liu, “ChunkFlow: Towards Continuity-Consistent Chunked Policy Learning,” *arXiv preprint arXiv:2607.12992*, 2026.
- [29] Q. He, Z. Yang, W. Liang, C. Hao, N. Sebe, and J. Tian, “FocalPolicy: Frequency-Optimized Chunking and Locally Anchored Flow Matching for Coherent Visuomotor Policy,” in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2026, arXiv:2605.15944.
- [30] K. Fang, H. Pei, and X. Chi, “Smoother Action Chunking Flow Policy via Prior-Corrected Orthogonal Trust-Region Guidance,” *arXiv preprint arXiv:2605.24433*, 2026.
- [31] S. Jiang, X. Fang, N. Roy, T. Lozano-Pérez, L. P. Kaelbling, and S. Ancha, “Streaming Flow Policy: Simplifying Diffusion/Flow-Matching Policies by Treating Action Trajectories as Flow Trajectories,” in *Proc. Conf. Robot Learn. (CoRL)*, 2025.
- [32] M. Dai, Q. Zhuang, H.-Y. Xu, Y.-J. Shuai, Y. Wang, Q. Dou, and X.-S. Wei, “Where Should Action Generation Begin? A Learnable Source Prior for Generative Robot Policies,” *arXiv preprint arXiv:2606.17408*, 2026.
- [33] X. Jia, D. Blessing, X. Jiang, M. Reuss, A. Donat, R. Lioutikov, and G. Neumann, “Towards Diverse Behaviors: A Benchmark for Imitation Learning with Human Demonstrations,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2024.